

Relatório Acadêmico - Experimento 700k / 50 Clientes

```
@page { size: A4; margin: 1.8cm; }
body { font-family: "Liberation Serif", "DejaVu Serif", serif; color: #111827;
line-height: 1.55; font-size: 11pt; }
h1, h2, h3 { color: #0f172a; margin-top: 1.15em;
margin-bottom: 0.45em; }
h1 { font-size: 22pt; border-bottom: 2px solid #1e293b;
padding-bottom: 8px; }
h2 { font-size: 16pt; border-bottom: 1px solid #cbd5e1;
padding-bottom: 3px; }
h3 { font-size: 13pt; }
p { margin: 0.45em 0; text-align: justify; }
ul { margin: 0.35em 0 0.7em 1.25em; }
li { margin: 0.18em 0; }
code { background: #f1f5f9; padding: 0.12em 0.25em; border-radius: 3px; font-family:
"Liberation Mono", monospace; font-size: 10pt; }
pre { background: #f8fafc; border: 1px solid #cbd5e1; padding: 10px; white-space: pre-wrap; font-family: "Liberation Mono",
monospace; font-size: 9.3pt; line-height: 1.35; }
table { border-collapse: collapse; width: 100%; margin: 0.6em 0 1em 0; font-size: 10pt; }
th, td { border: 1px solid #cbd5e1; padding: 6px 8px; vertical-align: top; }
th { background: #e2e8f0; text-align: left; }
.capa { min-height: 720px; display: flex; flex-direction: column; justify-content: space-between; text-align: center; page-break-after: always; }
.capa h1 { border: none; font-size: 24pt; margin-top: 2.5cm; }
.capa .subtitle { font-size: 14pt; line-height: 1.6; }
.capa .meta { font-size: 12pt; line-height: 1.7; margin-bottom: 1.5cm; }
.ok { background: #f0fdf4; border-left: 4px solid #16a34a; padding: 10px 12px; margin: 0.8em 0; }
.warn { background: #fff7ed; border-left: 4px solid #ea580c; padding: 10px 12px; margin: 0.8em 0; }
```

Relatório Acadêmico Completo

Experimento de Aprendizado Federado com 700.000 logs e 50 clientes sobre o dataset CIC-IDS2018

Thuesday-20-02-2018_TrafficForML_CICFlowMeter.csv
Projeto: FL_RANSOM_LLM
Experimento: WiFi_CICIDS2018
de geração: 27/03/2026
Raiz do projeto: /home/weverton/Artigo-LANC-Thiago/FL_RANSOM_LLM

Resumo

Este relatório documenta de forma aprofundada o experimento final configurado com 700.000 logs processados do dataset CIC-IDS2018 Tuesday e 50 clientes federados no repositório FL_RANSOM_LLM. O objetivo foi consolidar uma configuração computacionalmente viável e metodologicamente mais realista do que os experimentos preliminares, preservando a lógica de detecção de anomalias baseada em aprendizado do comportamento benigno e avaliação posterior em conjunto misto.

A configuração final utilizou 560.000 fluxos benignos para treino, 70.000 fluxos benignos para teste e 70.000 fluxos anômalos para teste, totalizando 700.000 logs. O cenário federado foi organizado em 50 clientes com divisão IID, participação de 20% dos clientes por rodada, 5 rodadas federadas, 10 clientes selecionados por rodada, 2 GPUs e 20 passos de treino por cliente selecionado em cada rodada.

O melhor resultado observado ocorreu em K=1 na rodada 3, com $F1 = 0.6962$, $Precis\grave{a}o = 0.5367$, $Revocac\~ao = 0.9906$, $FPR\ Benigna = 0.8551$. Em comparação com o experimento anterior de 250 mil logs e 2 clientes, houve leve ganho em F1 e pequena redução da FPR benigna, indicando melhoria incremental, embora a taxa de falso positivo ainda permaneça alta para uso operacional.

Palavras-chave: aprendizado federado, detecção de anomalias, CIC-IDS2018, modelos de linguagem, LoRA, análise de tráfego de rede, otimização de experimentos.

Abstract

This report presents a complete academic account of the final 700k-log / 50-client experiment conducted on top of the FL_RANSOM_LLM repository using the CIC-IDS2018 Tuesday flow dataset. The experiment was designed to balance computational practicality and methodological realism after earlier smaller and much larger trial configurations.

The final setup used 560,000 benign training flows, 70,000 benign test flows, 70,000 anomalous test flows, 50 IID clients, 20% client participation per round, and 5 federated rounds. The best result was obtained at round 3 with top-1 F1 = 0.6962. The new setup slightly improved F1 and benign false-positive rate over the previous 250k / 2-client experiment, while remaining much more operationally feasible than the full-dataset attempt.

1. Introdução

Após a integração bem-sucedida do dataset CIC-IDS2018 Tuesday ao repositório, surgiram três cenários experimentais distintos: um experimento reduzido com 250 mil logs e 2 clientes, uma tentativa de execução do dataset completo com treinamento por época que se mostrou excessivamente custosa, e por fim o experimento atual, concebido como compromisso entre fidelidade e viabilidade.

O experimento com 700 mil logs e 50 clientes foi escolhido porque preserva diversidade de dados, introduz um cenário federado mais próximo de um ambiente multi-cliente real e, ao mesmo tempo, mantém tempo de execução compatível com ciclos iterativos de pesquisa. Além disso, ele permite analisar explicitamente o efeito de aumentar a quantidade de clientes sem levar o treinamento a uma escala operacionalmente inviável.

Este relatório é mais completo do que a documentação anterior porque não apenas descreve as mudanças de código e os artefatos gerados, mas também situa o experimento atual dentro da trajetória de adaptação do projeto, compara quantitativamente os resultados com o baseline anterior e explicita as implicações metodológicas de cada decisão de configuração.

2. Contexto, Motivação e Histórico da Adaptação

A trilha de Wi-Fi do repositório não havia sido inicialmente projetada para processar um CSV massivo de fluxos de rede. A implementação original dependia de dois pequenos arquivos demonstrativos e de um conjunto simplificado de atributos. Isso foi adequado apenas enquanto o objetivo era demonstrativo.

A primeira grande adaptação tornou o pipeline capaz de ingerir o arquivo `Thursday-20-02-2018_TrafficForML_CICFlowMeter.csv` diretamente de `data/wifi/raw/`. Em seguida, foram introduzidos controles de cap para permitir experimentação progressiva. O experimento de 250 mil logs e 2 clientes validou a funcionalidade geral do pipeline, mas ainda representava um cenário pequeno. A tentativa subsequente com o dataset completo mostrou que treinar com todos os dados e todas as épocas tornaria o custo temporal excessivo.

O cenário de 700 mil logs e 50 clientes nasce justamente dessa transição: ele mantém o pipeline real, usa o dataset original sem adulterá-lo, aumenta o número de clientes e amplia o volume de dados em relação ao primeiro experimento, mas faz isso dentro de um orçamento de tempo claramente mais controlado.

3. Dataset Utilizado e Estratégia de Armazenamento

O dataset utilizado é o arquivo `Thursday-20-02-2018_TrafficForML_CICFlowMeter.csv`, pertencente à base CIC-IDS2018. O arquivo bruto foi mantido em `data/wifi/raw/`, enquanto todos os artefatos derivados ficaram em `data/wifi/processed/`. Essa separação preserva reprodutibilidade, evita alterações acidentais sobre o dado original e facilita refazer o experimento com diferentes configurações.

A estrutura final do trabalho manteve o dado bruto como fonte imutável e tratou o conjunto processado como artefato descartável e recriável. Isso foi importante porque ao longo do projeto houve múltiplas iterações de configuração, incluindo o experimento

anterior, a tentativa full dataset e o experimento 700k + 50 clientes.
Dimensies observadas no servidor.Dados brutos: 3.8G
/home/weverton/Artigo-LANC-Thiago/FL_RANSOM_LLM/data/wifi/rawDados processados: 1001M
/home/weverton/Artigo-LANC-Thiago/FL_RANSOM_LLM/data/wifi/processedResultados do
experimento atual: 475M
/home/weverton/Artigo-LANC-Thiago/FL_RANSOM_LLM/results/WiFi_CICIDS2018_Tuesday_700k

4. Mudanças Estruturais no Código

O experimento atual reaproveita as mudanças estruturais já incorporadas ao projeto. Essas mudanças incluem a refatoração completa do processador de dados, a introdução de um arquivo de configuração específico para Wi-Fi/CIC-IDS2018, o uso de paralelismo controlado entre GPUs, a parametrização conservadora do DataLoader e a reescrita da avaliação para inferência em lotes.

O arquivo `src/data_processing/wifi_processor.py` passou a ler um único CSV real, normalizar os rótulos, preservar metadados importantes e construir o campo `Contents` somente depois da aplicação dos caps. Essa última alteração reduziu drasticamente trabalho desnecessário no pré-processamento.

O arquivo `src/federated_learning/client.py` passou a aceitar tanto treinos por número fixo de passos quanto treinos dirigidos por época. Para o experimento atual, optou-se por `max_steps = 20` por cliente selecionado em cada rodada, o que limita o custo de execução.

O arquivo `src/federated_learning/server.py` já suportava paralelismo, mas foi configurado e refinado para respeitar limites explícitos de GPU. Já o arquivo `src/evaluation/evaluator.py` passou a trabalhar em lotes, tornando a avaliação de 140 mil fluxos por rodada viável em tempo razoável.

5. Configuração Final do Experimento 700k + 50 Clientes

A configuração final procurou refletir três objetivos simultâneos: aumentar o tamanho do experimento, introduzir número maior de clientes e manter tempo de execução aceitável. Para isso, o conjunto processado foi limitado a 700 mil logs no total, preservando a lógica de treino benign-only do projeto.

Os 560 mil logs de treino foram distribuídos IID entre 50 clientes, produzindo 11.200 exemplos benignos por cliente. Em cada rodada, 20% dos clientes são selecionados, o que resulta em 10 clientes participantes. Como o servidor dispõe de duas GPUs, esses 10 clientes são processados em 5 batches de 2 clientes.

Item	Valor
Logs totais do experimento	700.000
Treino benigno	560.000
Teste benigno	70.000
Teste anômalo	70.000
Clientes totais	50
Fração de clientes por rodada	0,2
Clientes selecionados por rodada	10
Batches de clientes por rodada	5 batches de 2 clientes
Amostras de treino por cliente	11.200
Rodadas federadas	5
Passos máximos por cliente/rodada	20
Tempo total de treino observado	09m 27s
Tempo médio por rodada	01m 53s
Tempo típico de treino por cliente	~15,2s a ~15,7s

Cliente	Amostras
0	11200
1	11200
2	11200
3	11200
4	11200
5	11200
6	11200
7	11200
8	11200
9	11200
10	11200
11	11200
12	11200
13	11200
14	11200
15	11200
16	11200
17	11200
18	11200
19	11200
20	11200
21	11200
22	11200
23	11200
24	11200
25	11200
26	11200
27	11200
28	11200
29	11200
30	11200
31	11200
32	11200
33	11200
34	11200
35	11200
36	11200
37	11200
38	11200
39	11200
40	11200
41	11200
42	11200
43	11200
44	11200
45	11200
46	11200
47	11200
48	11200
49	11200

Observação metodológica importante. Embora o experimento use 560 mil exemplos benignos no pool de treino, cada cliente selecionado executa apenas 20 passos por rodada. Portanto, o cenário atual não percorre integralmente todo o shard local em cada rodada; ele usa um orçamento de passos controlado para manter viabilidade computacional.

6. Como o Cenário com 50 Clientes Funciona na Prática

Comnum_clients = 50eclient_frac = 0.2, a seleçªo por rodada 0 calculada como int(50 * 0.2) = 10. Essa l3gica decorre diretamente da implementaçªo do servidor federado.

Como o servidor possui apenas 2 GPUs, esses 10 clientes nªo sªo executados todos simultaneamente. Eles sªo quebrados em 5 batches sequenciais por rodada, cada batch contendo 2 clientes treinando em paralelo, um em cada GPU. Esse comportamento foi efetivamente observado nos logs, que mostraram sequªncias do tipo Processing client batch 1/5at05/5.

7. Execuçªo Observada e Comportamento Temporal

O treino completo terminou em 09m27s, com m3dia de 01m53s por rodada. Cada batch de clientes levou aproximadamente 15 segundos para concluir seus 20 passos, o que 0 coerente com o tempo global observado por rodada.

Esse resultado 0 importante porque mostra que o aumento do nªmero de clientes nªo inviabilizou o experimento. Ao contrÆrio, com um orçamento controlado de passos por cliente, foi poss3vel escalar de 2 para 50 clientes mantendo a execuçªo em um intervalo de tempo muito razoÆvel para pesquisa iterativa.

Em seguida, a avaliaçªo percorreu as 5 rodadas e processou o conjunto de teste completo de 140 mil fluxos em cada checkpoint. A fase de avaliaçªo foi concluída com sucesso e gerou os arquivos f1_scores.csv, temporal_metrics.csv e communication_metrics.csv.

8. Resultados Quantitativos do Experimento Atual

8.1 Melhores resultados por valor de K

K	Melhor Rodada	Limiar	F1	Precisªo	Revocaçªo	FPR Benigna
1	3	0.90	0.6962	0.5367	0.9906	0.8551
5	5	0.97	0.6754	0.5156	0.9790	0.9198

8.2 Resultados completos por rodada

Rodada	K	Limiar	F1	Precisªo	Revocaçªo	FPR Benigna
1	1	0.78	0.6723	0.5071	0.9972	0.9691
1	5	0.93	0.6712	0.5064	0.9950	0.9699
2	1	0.89	0.6906	0.5298	0.9917	0.8801
2	5	0.98	0.6722	0.5074	0.9952	0.9660
3	1	0.90	0.6962	0.5367	0.9906	0.8551
3	5	0.98	0.6751	0.5109	0.9946	0.9520
4	1	0.91	0.6960	0.5361	0.9921	0.8586
4	5	0.97	0.6754	0.5160	0.9774	0.9170
5	1	0.92	0.6961	0.5353	0.9950	0.8638
5	5	0.97	0.6754	0.5156	0.9790	0.9198

8.3 M3tricas temporais

Rodada	K	TTD M3dio (s)	TTD Mediano (s)	Cobertura	FPR Benigna	Dispositivos Atac
1	1	0.0000	0.0000	1.0000	0.9691	10
1	5	0.0000	0.0000	1.0000	0.9699	10
2	1	0.0000	0.0000	1.0000	0.8801	10
2	5	0.0000	0.0000	1.0000	0.9660	10
3	1	0.0000	0.0000	1.0000	0.8551	10
3	5	0.0000	0.0000	1.0000	0.9520	10
4	1	0.0000	0.0000	1.0000	0.8586	10
4	5	0.0000	0.0000	1.0000	0.9170	10
5	1	0.0000	0.0000	1.0000	0.8638	10

	5		5		0.0000		0.0000		1.0000		0.9198		10
--	---	--	---	--	--------	--	--------	--	--------	--	--------	--	----

8.4 Møtricas de comunicaçªo

	Rodada		Clientes Selecionados		Bytes Totais		Bytes Mødios/Cliente		Parªmetros Totais		
	1		10		18432000		1843200.0		4608000		FedAvg
	2		10		18432000		1843200.0		4608000		FedAvg
	3		10		18432000		1843200.0		4608000		FedAvg
	4		10		18432000		1843200.0		4608000		FedAvg
	5		10		18432000		1843200.0		4608000		FedAvg

9. Comparaçªo com o Experimento Anterior (250k / 2 clientes)

Uma vantagem desta documentaçªo º situar o experimento atual em relaçªo ao baseline anteriormente executado com 250 mil logs e 2 clientes. Essa comparaçªo º relevante porque mostra que o aumento do volume de dados e do nªmero de clientes nªo apenas permaneceu viªvel, mas tambºm trouxe uma pequena melhoria quantitativa nas møtricas centrais.

No baseline anterior, o melhor ponto para $K=1$ foi obtido na rodada 2, com $F1 = 0.6949$ e $FPR\ Benigna = 0.8604$. No experimento atual, o melhor ponto surgiu na rodada 3, com $F1 = 0.6962$ e $FPR\ Benigna = 0.8551$.

	Cenªrio		Melhor Rodada		F1		Precisªo		Revocaçªo		FPR Benigna
	Experimento anterior (250k / 2 clientes)		2		0.6949		0.5352		0.9907		0.8604
	Experimento atual (700k / 50 clientes)		3		0.6962		0.5367		0.9906		0.8551
	Delta (atual - anterior)		-		0.0013		0.0015		-0.0001		-0.0054

Em termos absolutos, o ganho foi modesto, mas real: delta de $F1 = 0.0013$ e delta de $FPR\ Benigna = -0.0054$. Como a FPR diminuiu, esse delta negativo º positivo do ponto de vista operacional.

10. Interpretaçªo dos Resultados

O melhor resultado do experimento atual ocorreu em $K=1$ na rodada 3, com $F1 = 0.6962$. Isso indica que o modelo estª efetivamente aprendendo um sinal ºtil de separaçªo entre trªfego benigno e trªfego anªmal. A precisªo ficou em torno de 0.5367, enquanto a revocaçªo permaneceu extremamente alta, em 0.9906.

Essa combinaçªo revela um padrªo jª visto em experimentos anteriores: o modelo quase nªo perde anomalias, mas continua classificando benignos demais como suspeitos. Em outras palavras, o sistema se mostra sensível, porºm ainda pouco específico.

O fato de a melhor rodada ter surgido em torno da rodada 3, com estabilidade nas rodadas 4 e 5, sugere que o processo convergiu rapidamente. Isso reforça a escolha de manter 5 rodadas, jª que aumentª-las substancialmente provavelmente geraria custo adicional maior do que o benefício incremental em desempenho.

11. Limitaçªes e Consideraçªes Metodolªgicas

- O treino permanece benign-only, coerente com a proposta do projeto, mas isso limita comparaçªes com abordagens supervisionadas.
- O uso de `max_steps = 20` por cliente/rodada reduz custo, mas tambºm significa que cada cliente nªo percorre todo seu shard local a cada rodada.
- O limiar º selecionado com base em `f1_max`, estratªgia ºtil para anªlise experimental, mas nªo necessariamente ideal para um detector operacional.
- Ainda que o conjunto total seja maior do que o baseline anterior, ele continua sendo um recorte controlado do dataset bruto.

- A FPR benigna continua alta, o que indica necessidade de calibração adicional antes de qualquer uso operacional.

12. Conclusão

O experimento com 700 mil logs e 50 clientes representa, até o momento, o melhor compromisso entre realismo federado, custo computacional e capacidade de experimentação no contexto deste projeto. Ele se mostrou mais completo e informativo do que o cenário anterior, sem herdar a inviabilidade temporal da tentativa full dataset.

A execução foi estável, os resultados ficaram consistentes entre rodadas e houve leve melhora sobre o baseline anterior. O sistema continua apresentando alta sensibilidade e FPR benigna elevada, o que deixa claro que a próxima fronteira de melhoria não é apenas escalar o volume de dados, mas calibrar melhor o critério de decisão.

Como base para documentação, esse experimento fornece um retrato mais fiel do estado atual do projeto: código adaptado para dados reais, pipeline federado funcional, execução multi-GPU controlada, cenário com 50 clientes e métricas suficientemente ricas para orientar os próximos passos científicos.

Apêndice A. Inventário de Arquivos

```
FL_RANSOM_LLM/  
??? configs/config_wifi.yaml  
??? data/wifi/raw/Thursday-20-02-2018_TrafficForML_CICFlowMeter.csv  
??? data/wifi/processed/train.csv  
??? data/wifi/processed/test.csv  
??? data/wifi/processed/tokenized/  
??? results/WiFi_CICIDS2018_Tuesday/  
??? results/WiFi_CICIDS2018_Tuesday_700k/  
?   ??? client_data/client_data_metadata.json  
?   ??? communication_metrics.csv  
?   ??? f1_scores.csv  
?   ??? temporal_metrics.csv  
?   ??? round_0 ... round_5/  
??? src/data_processing/wifi_processor.py  
??? src/federated_learning/client.py  
??? src/federated_learning/server.py  
??? src/evaluation/evaluator.py  
??? docs/  
    ??? generate_wifi_report.py  
    ??? generate_wifi_report_academic_ptbr.py  
    ??? generate_wifi_report_700k_50clients_ptbr.py  
    ??? Relatorio_Academico_WiFi_700k_50clientes.pdf
```

Apêndice B. Configuração Completa do Experimento Atual

```
simulation_name: "WiFi_CICIDS2018_Tuesday_700k"  
  
dataset_name: "wifi"  
description: "WiFi/network-flow anomaly detection using the CIC-IDS2018 Tuesday flow  
CSV."  
  
data_base_path: "./data/"  
results_path: "./results/"  
  
# Raw dataset placement:  
#   data/wifi/raw/Thursday-20-02-2018_TrafficForML_CICFlowMeter.csv
```

```
raw_csv_file: "Tuesday-20-02-2018_TrafficForML_CICFlowMeter.csv"
label_column: "Label"
normal_label_values: ["Benign"]

# Flow-to-text conversion:
# The processor will use whichever of these columns are actually present in the CSV.
wifi_content_columns:
  - "Protocol"
  - "Flow Duration"
  - "Tot Fwd Pkts"
  - "Tot Bwd Pkts"
  - "TotLen Fwd Pkts"
  - "TotLen Bwd Pkts"
  - "Flow Byts/s"
  - "Flow Bytes/s"
  - "Flow Pkts/s"
  - "Flow IAT Mean"
  - "Fwd IAT Mean"
  - "Bwd IAT Mean"
  - "Pkt Len Mean"
  - "Pkt Len Var"
  - "SYN Flag Cnt"
  - "ACK Flag Cnt"
  - "PSH Flag Cnt"

# Split strategy:
# Only benign traffic is used for training.
train_benign_fraction: 0.8
benign_calibration_fraction: 0.0
random_seed: 42
test_balance: false

# Controlled-run controls:
# Total target for this experiment: ~700k logs
# - 560k benign logs for training
# - 70k benign logs for test
# - 70k anomalous logs for test
# This preserves the anomaly-detection logic of the project:
# training remains benign-only, and the test set mixes benign + anomaly.
raw_nrows: null
benign_train_cap: 560000
calibration_benign_cap: null
test_benign_cap: 70000
test_anomaly_cap: 70000

model_name: "HuggingFaceTB/SmolLM-135M"

lora: true
lora_rank: 8
lora_alpha_multiplier: 2
lora_dropout: 0.05

use_parallel_training: true
max_parallel_gpus: 2

num_rounds: 5
num_clients: 50
client_frac: 0.2
```



```
# Training policy for the 700k experiment:
# - max_steps remains capped for practicality.
# - Each selected client still trains for a controlled number of steps per round.
max_steps: 20
num_train_epochs: 1
logging_steps: 100
batch_size: 2
dataloading_num_workers: 4
dataloading_pin_memory: true
dataloading_persistent_workers: true
initial_lr: 0.001
lr_scheduler_type: "constant"
warmup_steps: 0

force_reprocess_data: true
evaluator_version: "new"
eval_batch_size: 4
eval_use_autocast: true
eval_torch_dtype: "float16"

top_k_values: [1, 5]
threshold_metric: "top1"
threshold_strategy: "f1_max"
f1_threshold_steps: 101
```

Apêndice C. Comandos de Reprodução

```
cd ~/Artigo-LANC-Thiago/FL_RANSOM_LLM\source venv/bin/activate\nrm -rf
results/WiFi_CICIDS2018_Tuesday_700k\nrm -rf data/wifi/processed/*\npython main.py
--config configs/config_wifi.yaml
```

Apêndice D. Evidências do Ambiente de Execução

```
avancos\nLinux avancos 6.17.0-19-generic #19-Ubuntu SMP PREEMPT_DYNAMIC Fri Mar 6
14:02:58 UTC 2026 x86_64 GNU/Linux
```

```
Architecture: x86_64
CPU op-mode(s): 32-bit, 64-bit
Address sizes: 46 bits physical, 48 bits virtual
Byte Order: Little Endian
CPU(s): 32
On-line CPU(s) list: 0-31
Vendor ID: GenuineIntel
Model name: 13th Gen Intel(R) Core(TM) i9-13900K
CPU family: 6
Model: 183
Thread(s) per core: 2
Core(s) per socket: 24
Socket(s): 1
Stepping: 1
CPU(s) scaling MHz: 88%
CPU max MHz: 5400.0000
CPU min MHz: 800.0000
BogoMIPS: 5990.40
Flags: fpu vme de pse tsc msr pae mce cx8 apic sep
mtrr pge mca cmov pat pse36 clflush dts acpi mmx fxsr sse sse2 ss ht tm pbe syscall nx
pdpe1gb rdtscp lm constant_tsc art arch_perfmon pebs bts rep_good nopl xtopology
```

nonstop_tsc cpuid aperfmperf tsc_known_freq pni pclmulqdq dtes64 monitor ds_cpl vmx smx est tm2 ssse3 sdbg fma cx16 xtpr pdcm pcid sse4_1 sse4_2 x2apic movbe popcnt tsc_deadline_timer aes xsave avx f16c rdrand lahf_lm abm 3dnowprefetch cpuid_fault epb ssbd ibrs ibpb stibp ibrs_enhanced tpr_shadow flexpriority ept vpid ept_ad fsgsbase tsc_adjust bmi1 avx2 smep bmi2 erms invpcid rdseed adx smap clflushopt clwb intel_pt sha_ni xsaveopt xsavec xgetbv1 xsaves split_lock_detect user_shstk avx_vnni dtherm ida arat pln pts hwp hwp_notify hwp_act_window hwp_epp hwp_pkg_req hfi vnmi umip pku ospke waitpkg gfni vaes vpclmulqdq rdpid movdiri movdir64b fsrm md_clear serialize pconfig arch_lbr ibt flush_lld arch_capabilities

Virtualization: VT-x
 L1d cache: 896 KiB (24 instances)
 L1i cache: 1.3 MiB (24 instances)
 L2 cache: 32 MiB (12 instances)
 L3 cache: 36 MiB (1 instance)
 NUMA node(s): 1
 NUMA node0 CPU(s): 0-31
 Vulnerability Gather data sampling: Not affected
 Vulnerability Ghostwrite: Not affected
 Vulnerability Indirect target selection: Not affected
 Vulnerability Itlb multihit: Not affected
 Vulnerability L1tf: Not affected
 Vulnerability Mds: Not affected
 Vulnerability Meltdown: Not affected
 Vulnerability Mmio stale data: Not affected
 Vulnerability Old microcode: Not affected
 Vulnerability Reg file data sampling: Mitigation; Clear Register File
 Vulnerability Retbleed: Not affected
 Vulnerability Spec rstack overflow: Not affected
 Vulnerability Spec store bypass: Mitigation; Speculative Store Bypass disabled via prctl
 Vulnerability Spectre v1: Mitigation; usercopy/swapgs barriers and __user pointer sanitization
 Vulnerability Spectre v2: Mitigation; Enhanced / Automatic IBRS; IBPB conditional; PBR SB-eIBRS SW sequence; BHI BHI_DIS_S
 Vulnerability Srbds: Not affected
 Vulnerability Tsa: Not affected
 Vulnerability Tsx async abort: Not affected
 Vulnerability Vmscape: Mitigation; IBPB before exit to userspace

	total	used	free	shared	buff/cache	available	
Mem:		123Gi	53Gi	9.1Gi	56Mi	61Gi	69Gi
Swap:		30Gi	452Ki	30Gi			

Apêndice E. Localização dos Arquivos Gerados

HTML:

/home/weverton/Artigo-LANC-Thiago/FL_RANSOM_LLM/docs/Relatorio_Academico_WiFi_700k_50clientes
 /home/weverton/Artigo-LANC-Thiago/FL_RANSOM_LLM/docs/Relatorio_Academico_WiFi_700k_50clientes
 atuais:
 /home/weverton/Artigo-LANC-Thiago/FL_RANSOM_LLM/results/WiFi_CICIDS2018_Tuesday_700k\nResult
 baseline:
 /home/weverton/Artigo-LANC-Thiago/FL_RANSOM_LLM/results/WiFi_CICIDS2018_Tuesday\nConfig:
 /home/weverton/Artigo-LANC-Thiago/FL_RANSOM_LLM/configs/config_wifi.yaml